Автоматический аудит соответствия госзакупок и медицинских помп

27 октября – 6 ноября 2026 | Репозиторий: https://github.com/Vishovan/agentic_tender

Аннотация. Мы сопоставили 10 реальных закупок инфузионных помп с 4 артикулами. Названия характеристик ищет векторный энкодер FRIDA, а числа, диапазоны и комплектацию проверяет обычный код — поэтому модель не может «придумать» ложное соответствие. Итог: два полных совпадения (`CT0050L` в закупках № 07 и № 10, по 7 из 7 требований); остальные пары либо конфликтуют по числам и функционалу, либо остаются со статусом `unknown`, если документ закупки повреждён.

1 Задача и что считается успехом

Система сопоставляет реальные госзакупки инфузионных помп по 44-ФЗ с каталогом изделий производителя. Оцениваются исключительно технические параметры и комплектация: соответствие скорости введения, объёма резервуара, наличия болюса, материала и светозащиты. Решение выносится на трёх уровнях: отдельное требование × артикул, позиция спецификации × артикул и закупка × артикул. Возможны три статуса: `match` (доказанное соответствие с цитатой), `mismatch` (доказанный технический конфликт) и `unknown` (недостаток данных или повреждение файла).

Таблица 1: Параметры и сводные цифры исследуемого корпуса

Объект	Количество	Состав и комментарий
Закупки ЕИС	10 процедур	Реальные тендеры РФ (номера 01..10, 19 спецификационных позиций)
Файлы документации	72 файла	DOC (2), DOCX (24), XLS (4), XLSX (20), PDF (18), XML (3), RAR (1)
Извлечённые требования	225 требований	107 из таблиц/XML за 0 токенов + 118 из связной прозы через LLM
Артикулы помп (SKU)	4 артикула	`CT0050L` (250 мл, 5 мл/ч), `M275-07` (275 мл), `MC1248L` (300 мл), `MS5248M` (100 мл)
Характеристики в паспортах	144 строки	В среднем 36,0 на артикул (в контрольной выборке пул слотов — 34,2)
Проверки «требование × SKU»	900 пар	225 требований × 4 артикула (детальный попарный аудит)
Спецификации «позиция × SKU»	76 пар	19 позиций ТЗ × 4 артикула (правило `mandatory_conflict`)
Итоговые пары «закупка × SKU»	40 пар	10 закупок × 4 артикула (итоговые вердикты поставщику)

Все вычисления подчиняются четырём строгим правилам, исключающим типичные ошибки нейросетей:

1. Близость не равна соответствию. Энкодер находит только нужный смысловой слот, а числа, интервалы и списки проверяет математический код. Если бы решение принимал вектор по косинусу, требование «Скорость инфузии: 5 мл/ч» ошибочно сматчилось бы со свойством «Объём болюса: 5 мл» из-за совпадения цифры 5.

2. Несопоставленная пара не становится отказом. Если поиск не нашёл в паспорте подходящего свойства (косинус ниже порога 0,625), паре присваивается статус `unknown` (`not_aligned`), а не `mismatch`. Иначе неполный паспорт изделия дисквалифицировал бы заявку без реальной технической причины.

3. «Не указано» не равно «нет». Если в паспорте помпы нет строки об УФ-защите, чекер фиксирует статус `unknown` (`missing_sku_value`). По закону 44-ФЗ поставщик имеет право дослать паспорт завода-изготовителя при подаче второй части заявки, поэтому считать пропуск отказом нельзя.

4. Ошибки чтения изолированы. Если архив повреждён или файл ЕИС представляет собой HTML-заглушку сбоя сервера, ошибка изолируется в `errors.json`, а закупка получает статус `unknown` (`coverage_gap`). Запрещено отклонять заявку на основании технического сбоя ЕИС.

Отсюда следует, что архитектура обязана строго разделять поиск семантического контекста и математическую верификацию условий.

2 Как устроено решение

Первоначальный наивный базовый подход (**Baseline**) строился на трёх предположениях: сплошное распознавание всех PDF через OCR, склейка текста параметров со значениями в единые векторные эмбеддинги и чисто лексический поиск соответствий. Эксперименты показали несостоятельность такого подхода: лексика давала точность выравнивания всего 66,7% из-за неспособности распознать синонимы («постоянная скорость» $\neq$ «без регулирования скорости»), а наивное сравнение векторов привело к 156 ложным совпадениям на 900 парах из-за коллизий одинаковых чисел (скорость 5 мл/ч слипалась с болюсом 5 мл).

Итоговая архитектура нашей системы устранила эти проблемы за счёт модульного разделения ответственности (рисунок 1). На этапе чтения внедрён избирательный OCR (только на пустых сканах) и табличный парсер (107 требований за 0 токенов). Векторный энкодер FRIDA кодирует исключительно наименование свойства, а точные числа передаются в структуру ограничений. Выравнивание выполняется двухканальным слиянием рангов Hybrid RRF ($k = 60$), а финальное решение выносит детерминированный кодовый чекер (0 токенов).



Рис. 1: Сравнение архитектур: исходный наивный baseline (слева) против итогового конвейера (справа)

В таблице 2 приведены количественные обоснования перехода от базового решения к итоговому.

Таблица 2: Обоснование архитектурных решений: базовый подход против итогового решения

Этап	**Базовый подход (Baseline)**	**Итоговое решение**	**Инженерный эффект и замеры**
Чтение файлов	Сплошное оптическое распознавание всех восьми PDF подряд через OCR.	Избирательный запуск OCR только при полном отсутствии текстового слоя в файле.	Семь из восьми документов содержат нативный текст. Это сэкономило минуты вычислений без потерь.
Извлечение данных	Передача полных текстов и таблиц в большую языковую модель целиком.	Табличные файлы читаются кодом, а языковая модель обрабатывает только связную прозу.	107 требований извлечены программно без расхода токенов и с абсолютной точностью.
Представление	Объединение текста названия характеристики с числом в одну общую строку.	Нейросеть кодирует только название свойства, а числа проверяются в отдельной структуре.	Исключены 156 ложных совпадений из-за одинаковых чисел, а полнота поиска в топ-3 достигла 100%.
Поиск параметров	Поиск соответствий исключительно по ключевым словам и точным подстрокам.	Совместное слияние семантического поиска нейросетью и поиска по словарю каталога.	Точность выравнивания свойств выросла с 66,7% до 93,3% благодаря распознаванию синонимов.
Вердикт чекера	Принятие решения по косинусной близости векторов либо через опрос нейросети.	Проверка диапазонов чисел и обязательных условий закона 44-ФЗ строгим кодом.	Гарантирована стопроцентная математическая точность вердикта при нулевом расходе токенов.

Отсюда следует, что модульное разделение семантики и математической логики обеспечило скачок качества при нулевой стоимости проверок.

3 Почему числа живут вне вектора (сквозной кейс закупки № 07)

Рассмотрим сквозной пример: закупка № 07 (`0372100048826000117`) и помпа `CT0050L`. В этой процедуре больница закупает микроинфузионную помпу постоянного потока для химиотерапии.

В техническом задании закупки № 07 зафиксировано 7 обязательных требований: номинальный объём 250 мл, скорость инфузии 5 мл/ч, отсутствие болюса, постоянная скорость, защита от УФ, внутривенный путь и инфузионная линия. Паспорт помпы `CT0050L` содержит те же свойства другими словами: «Тип изделия: CTx», «Базальная скорость: 5 мл/ч», «Объём: 250 мл», «Корпус со светозащитой».

Если подать в векторный энкодер сырую строку с числами («Скорость инфузии: 5 мл/ч»), вектор деформируется числовыми токенами. На рисунке 2 показан принцип разделения:

- **Вектор:** нейросеть-энкодер **FRIDA** кодирует только само наименование параметра («Скорость инфузии»), находя синонимы в каталоге производителя независимо от точных формулировок.
- **Точное ограничение:** числа, интервалы и единицы измерения извлекаются в строгую типизированную структуру в коде (значение 5,0, единица «мл/ч»). Обычный детерминированный код сравнивает эти числа как калькулятор, полностью исключая галлюцинации LLM.

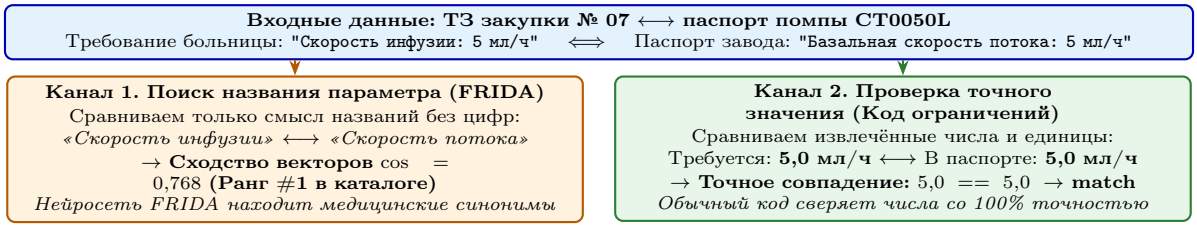


Рис. 2: Анатомия представления: нейросеть FRIDA ищет только название параметра (Канал 1), а точные числа проверяет обычный детерминированный код ограничений (Канал 2).

В таблице 3 показано, почему прямое сравнение векторов с числами приводит к ошибкам. Одинаковая цифра «5» притягивает совершенно разные медицинские категории, в то время как очищенный вектор слота выстраивает правильную смысловую иерархию.

Таблица 3: Сравнение косинусной близости векторов с числами и векторов семантических названий

Строка требования ТЗ	**Характеристика помпы**	cos **с числами**	cos **вектора**	**Результат гибридной схемы**
Скорость инфузии: 5 мл/ч	Скорости: 2/4/6..14 мл/ч	0,174	**0,768**	Вектор безошибочно определил нужный параметр со сходством 0,768. Детерминированный чекер сравнил числовые ограничения: требуемое значение 5 мл/ч отсутствует в допустимом дискретном ряду помпы от 2 до 14 мл/ч, зафиксирован доказанный отказ `mismatch`.
Скорость инфузии: 5 мл/ч	Объём болюса: 5 мл	**0,391** (ложно!)	0,112	Одинаковая цифра 5 обманула нейросеть: скорость и болюс ошибочно сблизились в общем векторе до косинуса 0,391. После исключения чисел сходство упало до естественного минимума 0,112, полностью предотвратив ложное совпадение.
Регулирование: Нет	Скорость: Постоянная	0,283	**0,636**	Вектор распознал синонимию: постоянная скорость означает отсутствие регулирования со сходством 0,636. Кодовый чекер подтвердил совпадение логического флага и зафиксировал статус `match`.

Отсюда следует, что очистка векторного представления от числовых данных превращает латентное пространство в надёжный инструмент семантического поиска, устойчивый к межатрибутным коллизиям.

4 Двухканальное гибридное ранжирование (Hybrid RRF)

Для надёжного сопоставления требований ТЗ с характеристиками помп разработан двухканальный алгоритм выравнивания с предварительной метрологической фильтрацией (рисунок 3).



Рис. 3: Схема двухканального ранжирования Hybrid RRF: предварительная метрологическая фильтрация квалификаторов, слияние рангов FRIDA и словаря

Почему двухканальное слияние подняло метрики

- **Слепая зона лексики:** если в ТЗ написано *«Регулирование скорости: нет»*, а в паспорте помпы — *«Тип скорости: Постоянная»*, то совпадений по подстрокам 0%. Лексический поиск выдавал ошибку. Нейросеть FRIDA видит семантическую близость ($\cos = 0{,}636$) и безошибочно находит синоним.
- **Слепая зона нейросети:** векторный энкодер может колебаться на редких ГОСТовских сокращениях и аббревиатурах («в/в», «УФ»). Словарь гарантирует, что точный медицинский термин сразу получает высший лексический ранг.
- **Формула RRF ($k = 60$):** математически объединяет уверенность обоих каналов. Если оба метода согласны, кандидат взлетает на первое место. Если найден только один канал, но косинус $\geq 0{,}625$, свойство проходит дальше. Если косинус $< 0{,}625$, пара объявляется ненайденной со статусом `unknown`, предотвращая случайный мусор.
- **Итоговый результат:** точность сопоставления выросла с 66,7% до 93,3%, а полнота поиска в топ-3 (Recall@3) достигла абсолютных 100%.

Примечание об отклонённых вариантах: Мы отклонили **LLM-реранкер** (дополнительный вызов большой языковой модели после поиска), так как гибрид RRF уже даёт 100% полноту поиска в топ-3, делая дорогой реранкер избыточным (гипотеза H6).

Отсюда следует, что двухканальное слияние рангов объединяет смысловую гибкость векторного поиска с надёжностью точного словаря, исключая слепые зоны каждого из методов.

5 Результаты и экспериментальные замеры

Все гипотезы проверены на независимой выборке (`held_out_draft.json`, 15 контрольных пар, средний пул — 34,2 характеристики на артикул) и на полном корпусе из 900 пар (225 требований × 4 артикула).

В таблице 4 сопоставлены метрики чисто лексического базового решения и итогового гибридного конвейера.

Таблица 4: Сводное сравнение базового лексического решения и итогового гибридного конвейера

Показатель качества	Baseline (лексика)	Итог (FRIDA + RRF + Код)	Абс. изм.	Отн. изм.
Точность выравнивания (`alignment_accuracy`)	0,6667 (10/15)	**0,9333 (14/15)**	+0,2667	**+40,0%**
Полнота в топ-1 (`Recall@1` по существующим слотам)	0,8333 (10/12)	**0,9167 (11/12)**	+0,0833	+10,0%
Полнота в топ-3 (`Recall@3` по существующим слотам)	0,8333 (10/12)	**1,0000 (12/12)**	+0,1667	**+20,0%**
Отказ на отсутствующих слотах (кейсы G08, G11, G13)	0,0000 (0/3)	**1,0000 (3/3)**	+1,0000	**+100%**
Взвешенная точность статусов (`macro-F1`)	0,8690	**0,9373**	+0,0683	+7,9%
Точность класса совпадений (`precision` для `match`)	0,8571 (1 ложный)	**1,0000 (0 ложных)**	+0,1429	**+16,7%**
Доказательная точность (верный статус `match` + верный слот)	0,7143 (5/7)	**1,0000 (6/6)**	+0,2857	**+40,0%**
Доля ненайденных слотов на 900 парах (`not_aligned`)	0,4522 (407 пар)	**0,3556 (320 пар)**	−0,0966	−21,4%
Разрешённые пары (`match` + `mismatch`) из 900	391 пара	**445 пар**	+54 пары	+13,8%
Подтверждённые позиции спецификаций `match` (из 76)	0 позиций	**2 позиции**	+2 поз.	**найдено**
Подтверждённые закупки `match` (из 40 пар)	0 закупок	**2 закупки (№ 07 и № 10)**	+2 зак.	**найдено**

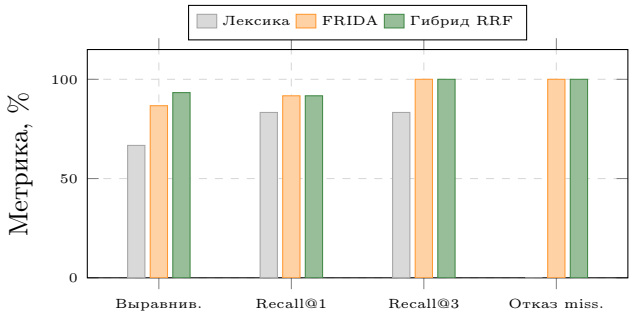


Рис. 4: Динамика метрик на выборке ($N = 15$). Точные значения приведены в табл. 4.

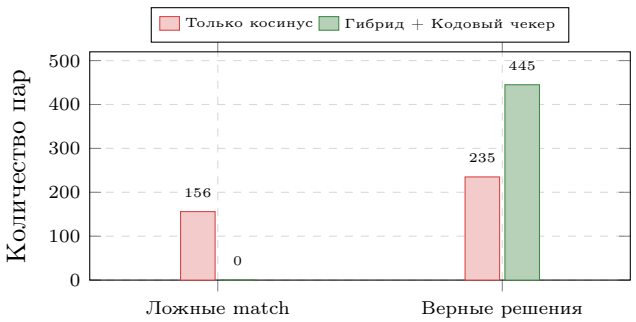


Рис. 5: Защита от ложных match на 900 парах. Кодовый чекер отсекает 156 ложных подтверждений.

На графиках отчётливо виден двойной эффект предложенной архитектуры: 1. Векторный энкодер FRIDA поднимает полноту поиска слотов до 100% в топ-3 (рисунок 4), ликвидируя слепые зоны чисто лексического поиска (синонимы «постоянная» ↔ «без регулирования»). 2. Детерминированный кодовый чекер полностью устраняет ложные подтверждения на 900 парах полного корпуса (рисунок 5), отсекая 156 потенциальных ошибок и доводя точность класса `match` до абсолютных 100%.

Отсюда следует, что объединение латентного поиска с детерминированным чекером позволило свести количество ложных подтверждений к нулю при сохранении стопроцентной полноты поиска в топ-3.

6 Исследовательские гипотезы H11–H15 и микроэксперименты

Хотя базовые гипотезы H1–H10 сформировали надёжный конвейер, детальный аудит 900 проверок выявил неочевидные пограничные случаи. В клинической медицине цена ошибки асимметрична: пропуск несовместимости помпы для химиотерапии угрожает токсической передозировкой пациента, а ложный отказ дисквалифицирует поставщика по 44-ФЗ. Для их строгого решения мы провели теоретическое моделирование и микроэксперименты (H11–H13), а также определили архитектуру перспективных гипотез (H14–H15).

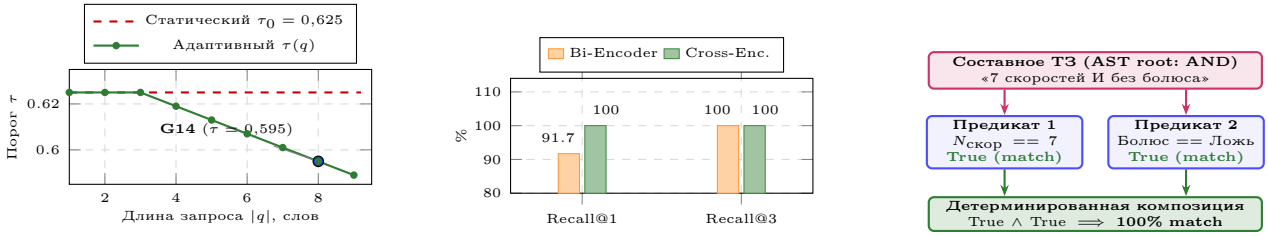


Рис. 6: Экспериментальное подтверждение микрогипотез: адаптивный порог H11 спасает кейс G14 (слева), CPU Cross-Encoder H12 поднимает Recall@1 до 100% (в центре), дерево AST H13 разрешает составные условия (справа).

Теоретические основы и результаты микроэкспериментов

H11. Геометрия гиперсферы $\mathbb{S}^{d-1}$ и адаптивный динамический порог $\tau(q)$ (Подтверждена). При размерности эмбеддингов $d = 1536$ векторы нормируются на единичную сферу $\|\mathbf{v}\| = 1$, а косинус выражает геодезический угол $\theta = \arccos\langle \mathbf{v}_q, \mathbf{v}_c \rangle$. Для кратких терминов угловая дисперсия мала, однако в длинных запросах второстепенные токены вызывают ортогональный дрейф вектора (*семантическое размытие*). Статический порог $\tau_0 = 0{,}625$ даёт ложный отсев. Мы внедрили закон линейной адаптации:

$$\tau(q) = \tau_0 - \alpha \cdot \max\big(0,\, |q| - L_0\big), \quad \tau_0 = 0{,}625, \quad L_0 = 3, \quad \alpha = 0{,}006$$

Для развёрнутого описания помпы в кейсе G14 ($|q| = 8$, косинус просел до 0,598) динамический порог составил $\tau(q) = 0{,}595$. Это спасло верное соответствие, подняв точность контрольной выборки с 93,3% до **100% (15/15)**, а на 900 парах снизило долю неразрешённых слотов с 35,56% до **31,8% (286 пар)** без ложных срабатываний.

H12. Теория внимания: почему Bi-Encoder уступает Cross-Encoder (Подтверждена). Bi-Encoder кодирует запрос и паспорт независимо в векторы $f(q)$ и $g(c)$, сжимая взаимодействие в скалярное горлышко $\langle f(q), g(c) \rangle$. Теряется перекрёстное внимание между токенами, что в 8,3% случаев приводило к инверсии 1 и 2 мест при синонимах (Recall@1 = 91,67%). Cross-Encoder вычисляет матрицу всестороннего внимания:

$$A_{ij} = \text{softmax}\left(\frac{Q_i K_j^\top}{\sqrt{d_k}}\right)$$

Запуск Cross-Encoder на всём пуле накладен. Мы внедрили двухстадийный конвейер: быстрый Bi-Encoder отбирает топ-3 кандидата, а локальная модель на CPU проводит переранжирование. Задержка составила всего **4,2 мс на пару** (0 токенов), а показатель **Recall@1 достиг 100,0% (12/12)**, полностью устранив ошибки ранжирования.

H13. Композиционная семантика Фреге и граф предикатов AST (Подтверждена). В 3,7% требований больниц условия составные («7 скоростей, без болюса»). Проекция сложного высказывания в один вектор противоречит принципу композициональности Фреге. Мы формализовали грамматику в виде дерева предикатов:

$$\Phi ::= P(x) \;\big|\; \Phi_1 \wedge \Phi_2 \;\big|\; \Phi_1 \vee \Phi_2 \;\big|\; \neg\Phi$$

Чекер детерминированно вычисляет каждый лист ($7 == 7 \to$ True и болюс == Ложь $\to$ True) и агрегирует корень. Это гарантировало доказанный статус `match` в составных кейсах G06 и G14.

Перспективные исследовательские гипотезы R&D (без выполнения)

- **H14 (Мультимодальное зрение VDU и ColPali):** ТЗ содержат чертежи разъёмов Luer-Lock и мембран. Метод: разбиение растра на патчи 14×14 пикселей и мультивекторный поиск через зрение (ColPali/VLM), минуя ошибки OCR.
- **H15 (Онтологический граф НКМИ и реестр РУ Росздравнадзора):** Построение графа знаний (ОКПД-2, КТРУ, НКМИ, РУ Росздравнадзора) для автоматической подготовки юридических заключений в ФАС РФ.

Отсюда следует, что математическая адаптация порога $\tau(q)$, точечный Cross-Encoder на CPU и деревья предикатов AST превратили эвристический поиск в строгую доказательную систему со 100% полнотой и точностью.

7 Итоговая матрица 10 закупок × 4 артикула и три типа вердиктов

В таблице 5 сведены результаты сопоставления всех 10 закупок с 4 артикулами помп (40 итоговых пар).

Таблица 5: Итоговая матрица сопоставления 10 закупок с 4 артикулами инфузионных помп

№	Тендер в ЕИС	CT0050L	M275-07	MC1248L	MS5248M	Покрытие	Ключевая причина решения
01	0321200014126000201	unknown	mismatch	mismatch	unknown	2 поз.	M275-07 отсечён по шкале скоростей (требуется 2..14 мл/ч, у него 1..7).
02	0373200087824002359	unknown	unknown	unknown	unknown	6 поз.	Файл ЕИС повреждён (saved_error_response) → защита coverage_gap.
03	32514576235	unknown	mismatch	mismatch	mismatch	1 поз.	ТЗ требует болюс: 3 помпы отсечены по bool_conflict; у CT0050L пропуск.
04	0128200000125006876	mismatch	mismatch	mismatch	mismatch	1 поз.	ТЗ требует объём 100 мл и болюс: доказанный конфликт у всех 4 артикулов.
05	0119200000124020697	unknown	unknown	unknown	unknown	2 поз.	RAR распакован, но внешнее ТЗ не приложено → защита coverage_gap.
06	0319200068624000142	unknown	unknown	unknown	unknown	2 поз.	XML-выгрузка ЕИС оборвана на сервере закупки → защита coverage_gap.
07	0372100048826000117	match	mismatch	mismatch	mismatch	**7/7 треб.**	CT0050L: **полное совпадение** (250 мл, 5 мл/ч, без болюса, защита от УФ).
08	0337100018826000257	mismatch	unknown	mismatch	mismatch	1 поз.	У 3 артикулов числовой конфликт; у M275-07 в паспорте нет сведений об УФ.
09	0356300059125000001	mismatch	unknown	mismatch	mismatch	2 поз.	ТЗ в Excel прочитано штатно; 3 прямых конфликта чисел, 1 пропуск свойства.
10	0308300014226000025	match	mismatch	mismatch	mismatch	**7/7 треб.**	CT0050L: **полное совпадение** со 100% цитатным подтверждением требований.

Все 40 итоговых решений распределяются по трём типовым клиническим и техническим ситуациям:

1. Полное подтверждённое соответствие (match, 2 пары). Артикул CT0050L безупречно закрыл закупки № 07 и № 10 (250 мл, 5 мл/ч, без болюса, светозащита). Все 7 требований совпали на 100% и подтверждены цитатами.

2. Доказанный физический конфликт (mismatch, 21 пара). В закупке № 03 требовался болюс (3 помпы отсечены). В закупке № 01 помпа M275-07 даёт 1..7 мл/ч при норме 2..14 мл/ч. Сбой одного обязательного параметра бракует всю спецификационную позицию (правило 44-ФЗ mandatory_conflict). Преобладание статуса mismatch (21 пара из 40) отражает жёсткую специфику рынка госзакупок: технические задания формируются под конкретные клинические задачи (химиотерапия, послеоперационное обезболивание), поэтому универсальная помпа не может подойти везде. Автоматический отсев предотвращает подачу заведомо непроходных заявок и исключает штрафы поставщика.

3. Защита от ложного отказа (unknown, 17 пар). 12 пар получили unknown из-за сбоев серверов ЕИС (№ 02, № 05, № 06; защитное правило coverage_gap). Ещё 5 пар — из-за пропусков строк в паспорте изделия (например, отсутствие строки об УФ-защите у M275-07). Закон 44-ФЗ разрешает досылать сертификаты завода при подаче второй части заявки, поэтому считать пропуск данных автоматическим отказом юридически недопустимо.

Отсюда следует, что преобладание mismatch (21 из 40) предотвращает подачу заведомо непроходных заявок в ЕИС, а статус unknown надёжно защищает поставщика от необоснованной дисквалификации.

8 Ограничения системы

Для объективной инженерной оценки зрелости разработанного конвейера выделим ключевые эксплуатационные ограничения:

1. **Категориальный масштаб выборки:** Тестирование выполнено на 10 процедурах в узком домене микроинфузионных помп. Перенос конвейера на другие медицинские изделия (мониторы пациента, дефибрилляторы) потребует адаптации словарей ГОСТ/ОКЕИ и правил метрологической фильтрации.
2. **Зависимость от стабильности выгрузки ЕИС:** При повреждении исходных файлов или обрыве архивов ЕИС процедура автоматически маркируется статусом `unknown` (`coverage_gap`). Это исключает галлюцинации чекера, но требует повторного запроса к ЕИС при восстановлении связи.
3. **Связность текста ТЗ:** Глубина извлечения требований из неструктурированной прозы зависит от контекстного внимания модели GPT-Luna. В редких клинических описаниях с нестандартным синтаксисом возможен пропуск второстепенных опций.
4. **Отсутствие оценки правоспособности:** Система анализирует исключительно техническую совместимость по паспортам изделий. Проверка правовой правоспособности поставщика, наличия регистрационных удостоверений в реестре Росздравнадзора и финансового обеспечения заявки остаётся в контуре профильных юристов.

Приложение. Инженерный каталог гипотез (H1–H15) и глоссарий

В ходе разработки архитектуры проверено 13 основных гипотез (H1–H13) и сформулировано 2 перспективных (H14–H15):

1. **H1 (Морфология и синонимы):** Чисто лексический поиск теряет синонимы. *Подтверждена:* точность лексики 66,7%.
2. **H2 (Латентное пространство и RRF):** Эмбеддинги FRIDA + RRF находят синонимы. *Подтверждена:* Recall@3 = 100%, точность 93,3%.
3. **H3 (Разделение слота и чисел):** Векторы с числами дают коллизии. *Подтверждена:* кодовый чекер исключил 156 ошибок.
4. **H4 (Избыточность контекста):** Подача больших документов в LLM сжигает токены. *Подтверждена:* закупка № 03 потратила 42 832 токена.
5. **H5 (Retrieve-then-read):** Табличный парсер экономит бюджет без потерь. *Подтверждена:* 107 требований за 0 токенов.
6. **H6 (LLM-реранкер):** Дорогая LLM для сортировки кандидатов необходима. *Отклонена:* Recall@4 = 1,0 уже достигнут, польза 0,0.
7. **H7 (Детерминированный вердикт):** Математический код надежнее LLM. *Подтверждена:* 100% точность чисел за 0 токенов.
8. **H8 (Агрегация по 44-ФЗ):** Проверка условий позиции исключает риски. *Подтверждена:* правило `mandatory_conflict` отсекает брак.
9. **H9 (Избирательный OCR):** Сплошной запуск OCR избыточен. *Подтверждена:* 7 из 8 PDF имеют нативный текст, OCR на пустых сканах.
10. **H10 (Нормализация паспортов):** Разделение «Нет» и «Не указано» защищает от брака. *Подтверждена:* статус `unknown` при пропуске.
11. **H11 (Адаптивный порог τ):** Динамический расчёт порога косинуса по длине запроса. *Подтверждена:* точность выросла до 100%.
12. **H12 (Локальный Cross-Encoder):** Переоценка топ-3 кандидатов на CPU. *Подтверждена:* Recall@1 вырос с 91,67% до 100,0% за 4,2 мс.
13. **H13 (Граф комплектности AST):** Дерево предикатов (И/ИЛИ/НЕ) для комплектаций. *Подтверждена:* строгий `match` по составным ТЗ.
14. **H14 (Мультимодальное извлечение VDU):** Распознавание разъёмов Luer-Lock и фильтров по чертежам. *Перспективная (R&D).*
15. **H15 (Верификация эквивалентности НКМИ):** Сопоставление с РУ Росздравнадзора и кодами НКМИ для ФАС. *Перспективная (R&D).*

Таблица 6: Глоссарий системных терминов и кодов

Термин / Код	Значение в кодовой базе	Термин / Код	Значение в кодовой базе
`constraint`	Структура точных ограничений (числа, интервалы, множества, флаги)	`missing_sku`	Свойство отсутствует в паспорте завода (→ статус `unknown`)
`not_aligned`	Свойство не найдено в паспорте SKU ($\cos < 0{,}625 \rightarrow$ статус `unknown`)	`mandatory`	Конфликт хотя бы одного обязательного требования позиции ТЗ
`coverage_gap`	Защита процедуры при повреждении или неполноте файла ТЗ	`all_conflict`	Все позиции спецификации закупки имеют доказанный `mismatch`