Ручная проверка отложенной выборки (`held_out_draft.json`)

Мы вручную вычитали и закрыли отложенную выборку в : проверили все 15 пар «требование × артикул» (`G01` – `G15`) и список требований первой позиции из прозового техзадания закупки `02` (`E01`). Каждую запись сверяли не по пересказу пайплайна, а напрямую по первичным файлам датасета — таблицам Word и Excel, XML-извещению ЕИС, PDF техзадания и карточкам четырёх помп.

Ниже собрано, зачем эта выборка была нужна, какие числа получились у базового конвейера и какие нетривиальные случаи вскрылись при проверке глазами.

1. Зачем делали эту разметку и что в неё вошло

До этого шага мы могли сравнивать версии пайплайна только друг с другом (так закрылись гипотезы `H1` , `H3` , `H6` , `H9` и `H10` в). Но три оставшиеся гипотезы без человеческого эталона проверить нельзя:

- `H2` **(эмбеддинги против поиска по словам)** упирается в вопрос: *ту ли вообще строчку в карточке SKU нашёл поиск?*
- `H7` **и** `H8` **(кодовый чекер против вердикта LLM и каскада)** требуют независимого ответа `match / mismatch / unknown` , чтобы посчитать честный `macro-F1` и точность класса `match` .

Поэтому в собраны две части:

1. **15 пар** `G01` **–** `G15` из четырёх разных закупок (`01` , `02` , `04` , `07`) и трёх видов источников: DOCX-таблицы (), XLSX-таблицы (), XML-извещения ЕИС () и PDF с прозой ().
2. **Блок** `E01` **—** полный список технических требований к Позиции № 1 на 5-й странице прозового PDF закупки `02` , извлечённый через `gpt-5.6-luna` .

2. Главный сюрприз в цифрах: почему общая гистограмма статусов обманчива

Если посмотреть только на общее распределение статусов по 15 парам, кажется, что базовый лексический пайплайн отработал без единой помарки:

- **Ответы базового пайплайна (`pipeline_status`)**: `7 match`, `4 mismatch`, `4 unknown`.
- **Ручной эталон (`gold_status`)**: те же самые `7 match`, `4 mismatch`, `4 unknown`.

Но внутри этих одинаковых сумм скрылись сразу две встречные ошибки и пять промахов выравнивания:

1. **Две ошибки статуса взаимно скомпенсировались**:
   - в `G11` пайплайн поставил **ложный** `match` там, где на самом деле `unknown`;
   - в `G12` пайплайн поставил `unknown` там, где на самом деле чистый `match`.
2. **Лексический поиск попал в нужную характеристику только в 10 парах из 15 (`66.7%`)**:
   - в пяти случаях (`G08`, `G11`, `G12`, `G13`, `G14`) функция либо вообще ничего не нашла, либо притянула чужую строку из карточки товара.
   - в трёх из этих пяти случаев (`G08`, `G13`, `G14`) итоговый статус случайно совпал с эталоном — дважды выручили защитные проверки в , а один раз (`G14`) совпал сам знак ответа, но цитата со стороны товара оказалась слишком общей и не доказывала все детали требования.

Отсюда получаются честные стартовые метрики нашего baseline на отложенной выборке (точка отсчёта для `H2`, `H7` и `H8`):

Метрика из	Значение baseline	Пояснение
Точность выравнивания характеристик (`gold_alignment_ok`)	**10 / 15 (`0.667`)**	Промахи на `G08`, `G11`, `G12`, `G13`, `G14`
Совпадение статусов (accuracy)	**13 / 15 (`0.867`)**	Перепутаны `G11` (ложный `match`) и `G12` (пропущенный `match`)
`macro-F1` по трём классам	**`0.869`**	`F1(match) = 0.857`, `F1(mismatch) = 1.000`, `F1(unknown) = 0.750`
Precision класса `match`	**6 / 7 (`0.857`)**	1 ложный `match` на `G11`
Доказательность решений `match`	**5 / 7 (`0.714`)**	Кроме ложного `G11`, в `G14` верный `match` опёрся на неполную цитату SKU
Извлечение требований Luna на `E01`	**12 / 12 (`1.000`)**	Пропущенных и лишних требований на стр. 5 нет

3. Подробный разбор интересных случаев

Случай 1 (`G11`). Тихий ложный `match`: номинальный объём против максимального

- **Карточка выборки**: .
- **Откуда требование**: закупка `01`, файл , таблица 1, строка 5 (`table-1!D5`, Позиция № 1; в JSON —):

  > *«Номинальный объем заполнения: ≥ 300 и ≤ 399»* (мл).

- **Что реально в карточке `CT0050L`**: в и про объём записаны четыре разные строки:
  1. `Характеристики!A5` (): `Номинальный объём резервуара = 250 мл`.
  2. `Характеристики!A6` (): `Допустимый объём заполнения = Не указано`.
  3. `Характеристики!A17` (): `Максимальный объём заполнения = 300 мл`.
  4. `Характеристики!A18` (): `Объём заполнения в таблице производителя = 240 мл`. В самой цитате французского каталога (`2 jours | 240 ml | 250 ml | 300 ml | 5 | CT0050L`) прямо видно, что это помпа на **250 мл** (штатное заполнение на двое

суток — 240 мл), а **300 мл** — это верхний предел, выше которого резервуар нельзя переливать.

- **Почему ошибся пайплайн**: правило `fill_volume` в ищет только корни `("объем", "заполнен")` и не отличает *номинальный* объём от *максимального*. Строку `A6` («Допустимый объём заполнения») фильтр пропустил, потому что там стоит `Не указано`, и взял следующую подходящую по ключу строку — `Максимальный объём заполнения = 300`. Число `300` попало на границу требуемого интервала `[300, 399]`, и чекер выдал ложный `match`.
- **Решение в эталоне**: `gold_alignment_ok = false`, `gold_status = "unknown"` (номинальный объём заполнения в карточке отдельно не установлен, а подменять его предельным переливом нельзя).

Случай 2 (`G12`). Потерянный `match`: разные слова об одном и том же свойстве

- **Карточка выборки**: .
- **Откуда требование**: закупка `01`, , строка 6 (`table-1!D6`, Позиция № 1;):

> *«Регулирование скорости инфузии: нет».*

- **Что в карточке `CT0050L`**: строка `Характеристики!A7` ():

> *«Тип скорости: Постоянная».*

- **Что здесь интересно**: по смыслу «постоянная скорость» и «регулирования скорости нет» — это одно и то же. Более того, автор кодового чекера заранее предусмотрел эту пару в : слово `"постоянная"` там лежит рядом со словом `"нет"`. Если бы эти две строки встретились в , чекер сразу вернул бы `match`.
- **Почему пара потерялась**: лексический поиск в повесил на требование ярлык `speed_control` (корни `"регулир"` + `"скорост"`), а на строку SKU `"Тип скорости"` — другой ярлык `infusion_speed` (только `"скорост"`). Запасной поиск по пересечению слов () насчитал всего одно общее слово из трёх (`скорости` из `{регулирование, скорости, инфузии}`, коэффициент Жаккара `0.33` при пороге `0.5`) и отбросил пару в `not_aligned`. Это самый наглядный кандидат на починку через плотные эмбеддинги в гипотезе `H2`.

- **Решение в эталоне**: `gold_alignment_ok = false`, `gold_status = "match"`.

Случай 3 (`G05` в паре с `G04`). Близко по смыслу, но несовместимо по числу

- **Карточки выборки**: и .
- **Откуда требование**: закупка `01`, , строка 9 (`table-1!D9`;):

> *«Скорость инфузии, мл/час: 5».*

- **Сравнение двух мультискоростных помп**:
  - У **`M275-07`** (`G04`, строка `Характеристики!A8`,) шкала регулятора идёт с шагом 1 мл/ч: `0 / 1 / 2 / 3 / 4 / 5 / 6 / 7 мл/ч`. Пятёрка в наборе есть → `match` (`value_in_sku_set`).
  - У **`MS5248M`** (`G05`, строка `Характеристики!A8`,) шкала идёт с шагом 2 мл/ч, только по чётным числам: `2 / 4 / 6 / 8 / 10 / 12 / 14 мл/ч`. Есть соседние скорости `4` и `6`, но режима `5 мл/ч` на переключателе нет → `mismatch` (`value_not_in_sku_set`).
- **Зачем этот случай нужен на защите**: задание () прямо просит показать пару, которая очень близка в векторном пространстве, но технически не подходит. Любой текстовый энкодер положит «Скорость инфузии 5 мл/ч» и «Настройки скорости 2/4/6/8/10/12/14 мл/ч» почти в одну точку, а кодовая проверка вхождения числа во множество () без колебаний разводит `M275-07` и `MS5248M` по разным вердиктам.
- **Решение в эталоне (`G05`)**: `gold_alignment_ok = true`, `gold_status = "mismatch"`.

Случай 4 (`G14`). Семь скоростей, режим «0» и почему черновик зря сомневался в восьмой ступени

- **Карточка выборки**: .
- **Откуда требование**: закупка `01`, , таблица 1, строка 36 (`table-1!D36`, Позиция № 2 — второй насос в том же документе;):

> *«7-мь вариантов выбора скорости с возможностью немедленной остановки инфузии (режим "0"): Наличие».*

- **Как мы распутали этот случай при проверке**:
    1. В предварительной заметке `note` черновика было высказано сомнение: у `M275-07` набор `0 / 1 / 2 / 3 / 4 / 5 / 6 / 7` содержит 8 чисел, а не 7. Но если посмотреть на две строки выше в самом ТЗ (, строка 34, `Скорость инфузии: 2:4:6:8:10:12:14`), там перечислено ровно **7 рабочих скоростей**, а положение `"0"` в медицинской формулировке идёт отдельно как режим немедленной остановки.
    2. Открываем карточку и видим прямое подтверждение обеих частей: в строке `Характеристики!A16` () записано `Рабочие скорости без режима «0» = 1 / 2 / 3 / 4 / 5 / 6 / 7` (ровно **7 рабочих скоростей**), а в строке `Характеристики!A9` () — `Режим остановки «0» = Да`.
    3. Значит, само это требование (конструкцию переключателя на 7 рабочих ступеней плюс стоп-режим `"0"`) помпа `M275-07` выполняет честно. А то, что сами числа скоростей в Позиции № 2 нужны другие (`2..14`, а не `1..7`), проверяется соседним атомарным требованием из строки 34 (), которое и переводит всю Позицию № 2 в `mismatch`.
- **Почему `gold_alignment_ok` всё равно `false`**: пайплайн поставил `match`, но привязался не к строкам `A8/A9/A16`, а к общей строке `Характеристики!A7` (`Тип скорости = Регулируемая`,), потому что фильтр не разрешает сравнивать булево слово `"Наличие"` со списком чисел `kind = "set"`. Одно слово `"Регулируемая"` не доказывает ни число ступеней, ни наличие нуля — будь у помпы три скорости без режима `"0"`, пайплайн так же поставил бы `match`.
- **Решение в эталоне**: `gold_status = "match"`, но `gold_alignment_ok = false`.

Случай 5 (`G08` и `G13`). Когда поиск по подстрокам цепляется за случайные слова, а чекер страхует от беды

Оба примера показывают слабость жёстких правил в на длинных формулировках и одновременно объясняют, зачем в чекере стоят защитные проверки перед сравнением значений:

- `G08` **— индивидуальная упаковка против газовой стерилизации** ():
    - В закупке `04` (, ячейка `Лист14!E17`;) написано: *«Упаковка индивидуальная стерильная: соответствие»*.
    - В карточке есть количество штук в коробке (`12`), факт стерильности изделия (`Характеристики!A28`) и способ стерилизации (`Mode de stérilisation : oxyde d’éthylène`, и), но нет ни слова про индивидуальный пакет на каждую помпу.

    - Правило `("sterile", ("стериль",))` в увидело корень `стериль` и привязало упаковку к стерилизации оксидом этилена (`gold_alignment_ok = false`). От ложного срабатывания спасло то, что слово `"соответствие"` разобралось как `kind = "reference"` , и честно остановился со статусом `unknown` (`requirement_unparsed`).

- `G13` **— хвост длинной фразы утаскивает поиск в объём резервуара** ():
    - В закупке `01` (, строка 14, `table-1!D14` ;) требуют: *«Механизм, контролирующий точность подачи раствора, и обеспечивающий гарантию точности инфузии при заполнении резервуара от 50% от объема резервуара: Наличие»*.
    - В сработало правило `("reservoir_volume", ("объем", "резервуар"))` — просто потому, что оба слова встретились в придаточном обороте на конце предложения. В результате требование про механизм точности соединилось с ячейкой `Номинальный объём резервуара = 250 мл` (`gold_alignment_ok = false`).
    - Здесь сработала уже защита единиц измерения из гипотезы `H10` (): парсер вытащил из `50%` единицу `pct` , увидел конфликт с `ml` у `250 мл` и вернул `unknown` (`unit_incompatible`). Поскольку у `CT0050L` данных о таком механизме действительно нет (эта строка есть только у `MS5248M` и `MC1248L`), эталонный статус тоже `unknown` .

Случай 6 (`G07` , `G15` и блок `E01`). Пустые ячейки SKU и сквозная проверка прозы из GPT-Luna

- `G07` **— отсутствие данных не равно отказу** ():
    - Закупка `01` требует `Защита от УФ-лучей: Да` (, строка 4). В карточке на строке `Характеристики!A13` () стоит `Не указано` (`knowledge = "not_established"` , цитата `—`). И поиск, и чекер отработали строго по правилам задания: характеристику нашли (`gold_alignment_ok = true`), но вместо `mismatch` вернули `unknown` (`missing_sku_value`).

- `G15` **и** `E01` **— проверка того, что достала** `gpt-5.6-luna` **из PDF закупки** `02` ():
    - В (текстовый дамп —) всего описаны **6 позиций помп** на страницах 5–9, и в основном прогоне модель извлекла все 6 позиций целиком — 65 требований в .
    - Для ручной контрольной выборки в `E01` взята Позиция № 1 со страницы 5. Сверка по тексту показала стопроцентное попадание: все 12 технических условий выписаны дословно, ни одно не потеряно, а адрес доставки (*п. Коммунарка, ул. Сосенский Стан*) и сроки поставки (*по 19.12.2025*) модель сама отфильтровала и в технические требования не потащила.

- В карточке `G15` одно из этих извлечённых требований (`Болюс: Нет.` со стр. 5) проходит дальше в кодовый чекер против `MS5248M` (`Болюс = Да`,) и штатно получает `mismatch`.

4. Итоговая сводка по всем 15 парам

ID	Закупка (источник)	SKU	Требование → строка SKU в пайплайне	Ответ пайплайна	Эталон (gold)	Выравнивание (align_ok)
G01	01 (DOCX, поз. 1)	MS5248M	Болюс: Нет → Болюс: Да	mismatch	mismatch	true
G02	01 (DOCX, поз. 1)	CT0050L	Болюс: Нет → Болюс: Нет	match	match	true
G03	01 (DOCX, поз. 1)	CT0050L	Скорость, мл/час: 5 → Настройки скорости: 5	match	match	true
G04	01 (DOCX, поз. 1)	M275-07	Скорость, мл/час: 5 → 0 / 1 / 2 / 3 / 4 / 5 / 6 / 7	match	match	true
G05	01 (DOCX, поз. 1)	MS5248M	Скорость, мл/час: 5 → 2 / 4 / 6 / 8 / 10 / 12 / 14	mismatch	mismatch	true
G06	01 (DOCX, поз. 2)	CT0050L	Номинальный объем резервуара: 100..124 → 250	mismatch	mismatch	true
G07	01 (DOCX, поз. 1)	M275-07	Защита от УФ-лучей: Да → Защита от УФ: —	unknown	unknown	true
G08	04 (XLSX, поз. 1)	CT0050L	Упаковка индив. стерильная: соответствие → оксид этилена	unknown	unknown	**false**
G09	04 (XLSX, поз. 1)	CT0050L	Система блокировки болюса: Нет → Нет	match	match	true
G10	07 (XML ЕИС)	CT0050L	Болюс: Нет → Болюс: Нет	match	match	true
G11	01 (DOCX, поз. 1)	CT0050L	Номинальный объем заполнения: 300..399 → Макс.: 300	**match**	**unknown**	**false**

ID	Закупка (источник)	SKU	Требование → строка SKU в пайплайне	Ответ пайплайна	Эталон (gold)	Выравнивание (align_ok)
G12	01 (DOCX, поз. 1)	CT0050L	Регулирование скорости: нет → *не найдено (null)*	**unknown**	**match**	**false**
G13	01 (DOCX, поз. 1)	CT0050L	Механизм точности от 50% объёма: Наличие → 250 мл	unknown	unknown	**false**
G14	01 (DOCX, поз. 2)	M275-07	7 вариантов скорости + режим "0" → Регулируемая	match	match	**false**
G15	02 (PDF, Luna)	MS5248M	Болюс: Нет. → Болюс: Да	mismatch	mismatch	true

5. Что эта проверка даёт для следующих шагов (H2 , H7 , H8)

1. **Блокировка снята**: файл переведён в `status = "reviewed"`, и теперь на нём можно запускать автоматический подсчёт метрик для `H2` , `H7` и `H8` .
2. **Понятна точная задача для латентного пространства (H2)**: нам нужно не просто поднять абстрактный `Recall@k` , а починить пять конкретных сбоев лексического выравнивания — соединить «Регулирование скорости» с «Типом скорости» (`G12`), перестать путать номинальный объём с максимальным (`G11`), не клеить упаковку к методу стерилизации (`G08`) и не улетать в «объём резервуара» из-за последних слов длинного предложения (`G13`).
3. **Зафиксирован ориентир для H7 и H8** : кодовый чекер ни разу не ошибся сам по себе там, где поиск подал ему правильную характеристику (все ошибки baseline на `G11` и `G12` родились на этапе выравнивания, до чекера). Это сильный аргумент в пользу каскада `H8` , где модель привлекается только к неразобранным случаям `unknown` , а не пересчитывает за кодом очевидные числа и булевы флаги.